

Proyecto aplicado: Reconstrucción y regularización en imágenes tomográficas

Métodos Computacionales, S2 2026


1. Introducción

Una tomografía computada permite observar el interior de un objeto sin abrirlo a partir de mediciones obtenidas mediante rayos X. En el modelo simplificado que utilizaremos en este trabajo, un emisor colimado genera una familia de rayos paralelos que atraviesan una sección del objeto y son registrados por un arreglo lineal de detectores ubicado del lado opuesto. Cada detector mide cuánta intensidad logra atravesar el objeto a lo largo de uno de esos rayos. Los materiales con mayor coeficiente de atenuación reducen más la intensidad del haz, mientras que aquellos con menor coeficiente de atenuación permiten que llegue una intensidad mayor al detector.

Como se ilustra en la Figura 1, para una orientación dada θ se adquiere un conjunto de mediciones correspondientes a rayos paralelos que atraviesan distintas regiones de una sección de corte. Al cambiar el ángulo θ , el sistema observa el mismo objeto desde una nueva dirección. Repitiendo este procedimiento para múltiples orientaciones se obtiene la información necesaria para intentar reconstruir la distribución de atenuación en el interior de la sección.



(a) Ejemplo de sección tomográfica.



(b) Modelo de adquisición con rayos paralelos.

Figura 1: Una tomografía permite reconstruir una sección del objeto a partir de mediciones tomadas desde múltiples orientaciones. A la izquierda se muestran 4 imágenes tomográficas de distintos cortes del cerebro humano; a la derecha, el modelo simplificado de adquisición que utilizaremos en este trabajo.

Si I_0 es la intensidad emitida por uno de los rayos de la Figura 1 e I es la intensidad registrada por el detector correspondiente después de atravesar el objeto, un modelo simplificado relaciona ambas cantidades mediante

$$I = I_0 \exp \left(- \int_{\ell} \mu(r) dr \right).$$

Aquí, $\mu(r)$ describe la atenuación del material en cada punto y ℓ representa el recorrido del rayo a través del

objeto. Al tomar logaritmos se obtiene una medición lineal en la atenuación:

$$-\log\left(\frac{I}{I_0}\right) = \int_{\ell} \mu(r) dr.$$

Por lo tanto, cada detector entrega esencialmente una suma de las atenuaciones encontradas a lo largo del recorrido de uno de los rayos.

En este trabajo práctico estudiaremos una versión discreta y simplificada del problema de reconstrucción de una imagen tomográfica. Representaremos una sección del objeto mediante una imagen pequeña, dividida en píxeles. Cada rayo producirá una medición asociada a la atenuación acumulada a lo largo de su recorrido y el conjunto completo de mediciones podrá escribirse como un sistema lineal de la forma

$$\mathbf{b} = A\mathbf{x}.$$

El vector $\mathbf{x}$ representará la imagen desconocida, cada fila de A describirá cómo un rayo atraviesa los distintos píxeles y $\mathbf{b}$ contendrá las mediciones del escáner.

Comenzaremos simulando la adquisición de una tomografía ideal. Luego estudiaremos qué ocurre cuando la cantidad de proyecciones no alcanza para determinar una imagen de manera única. Más adelante incorporaremos ruido, formularemos la reconstrucción como un problema de mínimos cuadrados e implementaremos métodos iterativos de optimización. Finalmente, incorporaremos una penalización de suavidad al problema de reconstrucción y estudiaremos el compromiso entre fidelidad a las mediciones y reducción del ruido.

2. Objetivos

Esperamos que logren:

- representar una imagen como un vector y una adquisición tomográfica como una transformación lineal;
- construir e interpretar una matriz de proyección a partir de un conjunto de rayos;
- relacionar la cantidad y orientación de las mediciones con el rango y el espacio nulo de una matriz;
- formular una reconstrucción con ruido como un problema de mínimos cuadrados;
- interpretar la solución de mínimos cuadrados como una proyección ortogonal;
- reconocer el rol de la matriz simétrica $A^T A$ y de sus valores propios;
- implementar gradiente descendiente y el método de Newton para minimizar funciones cuadráticas;
- construir matrices de diferencias para medir la falta de suavidad de una imagen;
- formular una reconstrucción regularizada mediante una penalización cuadrática de las diferencias entre píxeles vecinos;
- analizar el compromiso entre fidelidad a las mediciones, reducción de ruido y preservación de detalles.

3. Temario

- | | |
|-----------------------------|---------------------------|
| ■ Imágenes como vectores | ■ Formas cuadráticas |
| ■ Transformaciones lineales | ■ Valores propios |
| ■ Sistemas lineales | ■ Gradiente descendiente |
| ■ Rango y espacio nulo | ■ Método de Newton |
| ■ Mínimos cuadrados | ■ Regularización |
| ■ Proyecciones ortogonales | ■ Visualización en Python |
| ■ Matrices simétricas | |

4. Modelo de adquisición tomográfica

Geometría de adquisición

En este trabajo reconstruiremos una única sección bidimensional del objeto, como un corte visto desde arriba. La imagen desconocida se representará mediante una función de atenuación $\mu(u, v)$ definida sobre ese plano. Un valor alto de μ representa una región que atenúa fuertemente los rayos X; un valor bajo representa una región más transparente.

En un tomógrafo real, el paciente permanece aproximadamente fijo mientras el sistema de adquisición gira a su alrededor y registra mediciones desde múltiples orientaciones. En cada orientación, distintos rayos atraviesan el mismo plano de corte y producen un conjunto de mediciones. Desde el punto de vista matemático, rotar el sistema de adquisición alrededor del objeto es equivalente a mantener fija la dirección de los rayos y rotar el objeto en sentido contrario (como se esquematiza en la Figura 1).

Los tomógrafos modernos, además, utilizan geometrías de adquisición más complejas que la que consideraremos en este trabajo. En la tomografía computada convencional es habitual una geometría de haz en abanico, mientras que otros sistemas, como los de cone-beam CT, utilizan un haz cónico. Nosotros adoptaremos una idealización más sencilla denominada *geometría de haz paralelo*, que conserva la estructura esencial del problema de reconstrucción y permite concentrarnos en los aspectos algebraicos y numéricos.

Parametrización de los rayos

Representaremos cada punto del plano mediante el vector

$$\mathbf{p} = \begin{pmatrix} u \\ v \end{pmatrix} \in \mathbb{R}^2.$$

Para una orientación θ , definimos el vector normal unitario

$$\mathbf{n}_\theta = \begin{pmatrix} \cos \theta \\ \sin \theta \end{pmatrix}.$$

La ecuación central de esta parametrización es

$$\mathbf{n}_\theta^\top \mathbf{p} = u \cos \theta + v \sin \theta = s.$$

El producto interno es la proyección de $\mathbf{p}$ sobre $\mathbf{n}_\theta$. Al fijarla en s (ver Figura 2), estamos seleccionando todos los puntos de una recta perpendicular a $\mathbf{n}_\theta$:

$$\ell_{\theta,s} = \{ \mathbf{p} \in \mathbb{R}^2 : \mathbf{n}_\theta^\top \mathbf{p} = s \}.$$

Por lo tanto, θ fija la orientación de una familia de rayos paralelos y s selecciona uno de ellos. Como $\mathbf{n}_\theta$ tiene norma uno, s es además la distancia con signo entre el rayo y el origen; en el modelo de adquisición, cada valor de s corresponde a una posición del detector. Es importante notar que el ángulo θ describe la orientación de la *normal*, no la dirección de propagación del rayo. En cada adquisición se fija θ y se recorren distintas posiciones s . Luego se cambia el ángulo y se repite el proceso. Como θ y $\theta + \pi$ generan las mismas rectas, basta considerar

$$\theta \in [0, \pi).$$

A modo de ejemplo, se ilustran los casos $\theta = 0$ y $\theta = \pi/2$ que permiten verificar otras configuraciones del detector (ver Figura 3). Representaremos cada rayo mediante la recta completa $\ell_{\theta,s}$. Sin embargo, la medición acumula atenuación únicamente en la parte del rayo que atraviesa el objeto; fuera de esa región consideramos que $\mu(u, v) = 0$.






Figura 2: Todo punto $\mathbf{p}$ del rayo destacado tiene la misma proyección s sobre la normal $\mathbf{n}_\theta$.



(a) Caso $\theta = 0$: la ecuación es $u = s$ y los rayos son verticales.



(b) Caso $\theta = \pi/2$: la ecuación es $v = s$ y los rayos son horizontales.

Figura 3: Dos casos particulares. El ángulo θ describe la orientación de la normal: para $\theta = 0$ los rayos son verticales y para $\theta = \pi/2$ son horizontales.

Las mediciones y el sinograma

Cada detector registra la atenuación acumulada a lo largo de un rayo. Para un ángulo fijo θ , el conjunto de mediciones obtenido en las distintas posiciones s se denomina *proyección*.

Si utilizamos K ángulos y q posiciones de detector, organizaremos todas las mediciones en una matriz

$$S \in \mathbb{R}^{K \times q},$$

denominada *sinograma*. Cada fila de S corresponde a un ángulo de adquisición y cada columna, a una posición del detector.

La matriz S puede [visualizarse como una imagen](#), utilizando el valor de cada entrada para determinar la intensidad del píxel correspondiente, como se ilustra en la Figura 4. En esta representación aparecen trazas curvas: al cambiar el ángulo θ , un mismo punto del objeto contribuye en distintas posiciones s del detector. Esta variación es sinusoidal, de allí el nombre *sinograma*.

Para formular posteriormente el sistema lineal, recorreremos la matriz S por filas y almacenaremos sus Kq mediciones en un único vector

$$\mathbf{b} \in \mathbb{R}^m, \quad m = Kq.$$

Así, las primeras q componentes de $\mathbf{b}$ corresponden a las mediciones para el primer ángulo, las siguientes q al segundo, y así sucesivamente.

Discretización matricial

Representaremos la imagen tomográfica reconstruida mediante una matriz

$$X \in \mathbb{R}^{n \times n},$$

donde cada entrada contiene la atenuación correspondiente a un píxel. Para trabajar con álgebra lineal, apilaremos sus filas en un vector

$$\mathbf{x} \in \mathbb{R}^{n^2}.$$

En Python, ambas representaciones se relacionan mediante




Figura 4: Sinograma. La fila resaltada contiene la proyección correspondiente al ángulo θ_k .

```
x = X.reshape(-1)
X = x.reshape(n, n)
```

Una adquisición con K ángulos y q posiciones de detector produce

$$m = Kq$$

mediciones, que almacenaremos en el vector $\mathbf{b} \in \mathbb{R}^m$.

La relación entre la imagen X y estas mediciones se representa mediante una matriz

$$A \in \mathbb{R}^{m \times n^2}.$$

Cada fila de A corresponde a un rayo y cada columna, a un píxel. La entrada a_{rj} indica la longitud del tramo del rayo r que atraviesa el píxel j ; si no lo atraviesa, entonces $a_{rj} = 0$ (ver Figura 5).




Figura 5: Relación entre un rayo y una fila de A . Los píxeles atravesados producen entradas no nulas; los restantes producen ceros.

Por lo tanto, la medición producida por el rayo r es

$$b_r = \sum_{j=0}^{n^2-1} a_{rj} x_j = (A\mathbf{x})_r.$$

Al reunir todas las mediciones obtenemos el sistema lineal

$$\boxed{\mathbf{b} = A\mathbf{x}}.$$

Como cada rayo atraviesa solamente algunos píxeles, la mayoría de las entradas de A son cero: A es una matriz dispersa o rara. Por ejemplo, para una imagen de 32×32 píxeles, 60 ángulos y 46 posiciones de detector,

$$n^2 = 1024, \quad m = 60 \cdot 46 = 2760,$$

por lo que

$$A \in \mathbb{R}^{2760 \times 1024}, \quad \mathbf{x} \in \mathbb{R}^{1024}, \quad \mathbf{b} \in \mathbb{R}^{2760}.$$

Un primer modelo binario

Antes de trabajar con las longitudes con las que cada rayo atraviesa los píxeles, construiremos una versión binaria más sencilla de la matriz A . En este primer modelo, los píxeles con los que contribuye un rayo se seleccionan únicamente a partir de sus centros.

Identificamos cada píxel mediante sus índices (i, j) . Dados tres enteros α, β y s , diremos que el centro de un píxel pertenece al rayo discreto cuando

$$\alpha i + \beta j = s.$$

El par (α, β) determina la orientación de la familia y s selecciona uno de sus rayos. Esta regla imita la ecuación continua $\mathbf{n}_\theta^\top \mathbf{p} = s$, pero no calcula la intersección geométrica entre la recta y cada píxel. Por lo tanto, la recta de referencia puede atravesar píxeles cuyos centros no satisfacen la ecuación (ver Figura 6, derecha). En este modelo inicial esos píxeles no serán seleccionados.

Para cada rayo discreto r , la fila $\mathbf{a}_r^\top$ de A contiene un 1 en las posiciones de los píxeles seleccionados y un 0 en las restantes, como muestra la Figura 6. Por lo tanto,

$$b_r = \mathbf{a}_r^\top \mathbf{x}$$

es la suma de las intensidades de los píxeles cuyos centros pertenecen al rayo discreto.

Esta primera versión de la matriz A codifica solamente la pertenencia de los centros a los rayos discretos. En el modelo final, todo píxel geoméricamente atravesado contribuirá a la medición. Los unos se reemplazarán por las longitudes de intersección, lo que permitirá ponderar la contribución del rayo a cada píxel según la distancia que recorre en su interior.

Usaremos las direcciones $(1, 0)$ para seleccionar filas, $(0, 1)$ para seleccionar columnas, $(1, 1)$ y $(1, -1)$ para las dos familias de diagonales, y $(2, 1)$ para incorporar rayos con otra inclinación, entre otras.




Figura 6: Dos rayos discretos con distintas orientaciones. Las rectas discontinuas muestran la dirección geométrica de referencia, pero sólo se seleccionan los píxeles cuyos centros satisfacen la ecuación indicada. El valor s es la constante de esa ecuación y no necesariamente coincide con una fila o columna.

5. Uso de IA generativa

El uso de herramientas de IA generativa está permitido en este proyecto aplicado, siempre que sea un soporte para el aprendizaje y no un reemplazo del trabajo propio. Toda asistencia deberá estar documentada en la entrega (uso_ia.txt): qué herramienta se usó y para qué se usó.

Categoría	Descripción	Estado
Hacer todo el trabajo por mí	Usar IA para completar todos los ejercicios porque no tenía tiempo, estaba cansado o no le veía sentido al trabajo.	PROHIBIDO. Hablá con el docente para una alternativa.
Hacer el trabajo repetitivo	Usar IA para completar algunos ejercicios que considero repetitivos o que no aportan aprendizaje.	DESALENTADO. Consultá con el docente antes.
Arrancar / destrabarme	Usar IA para resumir consignas, planificar, armar un esquema o destrabarme cuando estoy trabado.	PERMITIDO. Documentá su uso en la entrega.
Pedir feedback	Usar IA para revisar mi razonamiento, detectar errores o recibir sugerencias sobre mi trabajo.	PERMITIDO. Documentá su uso en la entrega.
Ayudarme a aprender	Usar IA para explicar conceptos nuevos o difíciles paso a paso, con ejemplos o analogías.	FOMENTADO. Mencionalá su uso en la entrega.
Amplificar mi trabajo	Usar IA para ir más allá de lo que pide la consigna, explorar extensiones o profundizar.	FOMENTADO. Documentá su uso en la entrega.

6. Condiciones de entrega y modalidad de aprobación

La entrega deberá realizarse en un único archivo comprimido en formato .zip. El archivo deberá contener un notebook de Jupyter por ejercicio (ya ejecutado). Los notebooks deben incluir el código, las explicaciones, los gráficos solicitados y las respuestas conceptuales.

También se deberá entregar una presentación en formato .pdf que resuma las soluciones del trabajo práctico. Esta presentación podrá utilizarse como material de apoyo durante la instancia oral.

Además, deberán incluir un archivo uso_ia.txt en el que indiquen si utilizaron herramientas de IA generativa y, en caso afirmativo, en qué ejercicios y con qué propósito.

La estructura esperada de la entrega es la siguiente:

```
apellido-1_nombre-1_apellido-2_nombre-2_proyecto_aplicado.zip
|-- ejercicio_1.ipynb
|-- ejercicio_2.ipynb
|-- ...
|-- uso_ia.txt
|-- presentacion.pdf
|-- figuras/
|   |-- ejercicio_XX.png
|   |-- ejercicio_YY.png
|   |-- ...
```

Los notebooks deben poder ejecutarse de principio a fin sin errores y deben ser autocontenidos. Se recomienda utilizar solamente numpy, scipy y matplotlib. Si utilizan alguna otra biblioteca, deberán justificarlo brevemente.

Fechas de entrega

Las entregas estarán habilitadas desde el martes 15 de septiembre y podrán realizarse en cualquier momento hasta el lunes 2 de noviembre a las 23:59.

Importante: Cada grupo podrá entregar el trabajo cuando considere que está listo. Una vez realizada la entrega, se le asignará una fecha para la instancia oral.

Con el objetivo de reconocer la autonomía en la organización del aprendizaje, la planificación del trabajo y la dedicación sostenida desde etapas tempranas, se otorgará una bonificación sobre el puntaje del oral de acuerdo con la fecha de entrega:

Período de entrega	Bonificación
Del martes 15 al lunes 28 de septiembre, inclusive	+15 puntos
Del martes 29 de septiembre al lunes 12 de octubre, inclusive	+10 puntos
Del martes 13 al lunes 26 de octubre, inclusive	+5 puntos
Del martes 27 de octubre al lunes 2 de noviembre, inclusive	Sin bonificación

La bonificación sólo se aplicará si la instancia oral se encuentra aprobada antes de sumar esos puntos. Por lo tanto, no podrá utilizarse para convertir un oral desaprobado en uno aprobado. El puntaje del oral, incluyendo la bonificación, no podrá superar los 70 puntos.

Evaluación

La calificación se dividirá en dos componentes:

- la presentación entregada tendrá un valor de hasta 30 puntos;

- la instancia oral tendrá un valor de hasta 70 puntos.

En la evaluación de la entrega se tendrá en cuenta la corrección de las soluciones, la claridad de las explicaciones, la calidad de los gráficos, la organización del código y la presentación general del trabajo.

Durante la instancia oral deberán responder preguntas sobre los ejercicios entregados. Las preguntas podrán estar relacionadas con la implementación de las funciones, las decisiones tomadas en el código, la interpretación de los resultados y gráficos, o la formulación teórica que respalda alguna respuesta.

Para aprobar el trabajo práctico será necesario aprobar la instancia oral sin considerar la bonificación por entrega anticipada. Una entrega correcta o incluso perfecta no será suficiente si sus autores no pueden explicar cómo fue resuelta, qué decisiones tomaron, qué conceptos están involucrados o por qué los resultados obtenidos tienen sentido.

El uso de herramientas de IA generativa está permitido de acuerdo con las condiciones establecidas en este trabajo, pero no exime de comprender y poder explicar la totalidad de su entrega.

Ejercicios

En cada ejercicio se indica un tag de uso de IA generativa. La etiqueta **Sin IA** significa que el ejercicio debe resolverse sin asistencia de IA. La etiqueta **Asistencia para destrabar/corregir** significa que pueden usar IA para destrabarse, revisar errores o pedir feedback, pero la solución debe ser propia y verificada. La etiqueta **IA necesaria** significa que se espera que usen IA como herramienta de asistencia para programar, hacer debugging o explorar alternativas, comprendiendo cabalmente cada aspecto de la solución.

1. **Sin IA** Una imagen como matriz y como vector

Utilizaremos inicialmente una imagen de 8×8 píxeles, representada mediante la matriz $X_{\text{fantoma}} \in \mathbb{R}^{8 \times 8}$. Esta clase de imagen de prueba suele denominarse *fantoma*: no corresponde a un escaneo real, sino que fue construida para estudiar el algoritmo de reconstrucción en condiciones controladas.

Crear en Python la siguiente matriz:

```
X_fantoma = np.array([
    [0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0],
    [0.0, 0.0, 0.8, 0.3, 0.3, 0.3, 0.0, 0.0],
    [0.0, 0.8, 0.8, 0.8, 0.3, 0.3, 0.3, 0.0],
    [0.0, 0.3, 0.8, 0.3, 0.3, 0.3, 0.3, 0.0],
    [0.0, 0.3, 0.3, 0.3, 0.3, 0.5, 0.3, 0.0],
    [0.0, 0.3, 0.3, 0.3, 0.5, 0.5, 0.5, 0.0],
    [0.0, 0.0, 0.3, 0.3, 0.3, 0.5, 0.0, 0.0],
    [0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0],
], dtype=float)
```

- Visualizar X_{fantoma} mediante `plt.imshow`, utilizando una escala de grises con su referencia.
- Convertir X_{fantoma} en el vector $\mathbf{x}_{\text{fantoma}} \in \mathbb{R}^{64}$ mediante `reshape(-1)`, que apila las filas de la matriz. Llamaremos x_k al valor almacenado en la posición k , con $k = 0, \dots, 63$.
- Recuperar la matriz original a partir de $\mathbf{x}_{\text{fantoma}}$ y verificar numéricamente que ambas representaciones contienen la misma información.
- Explicar qué magnitud representa el valor de una componente x_k en el modelo tomográfico. Interpretar qué significan valores altos, bajos y nulos de esa componente.
- Modificar un píxel de X_{fantoma} y localizar qué componente x_k cambia. Suponiendo que los índices comienzan en cero, expresar mediante una ecuación la relación entre los índices (i, j) del píxel y su posición k en el vector.

2. Sin IA Simulación de un único rayo binario

Utilizaremos el fantoma del ejercicio anterior para simular una medición del modelo binario. Una dirección discreta está determinada por el par (α, β) y un desplazamiento entero s . El rayo correspondiente selecciona únicamente los píxeles cuyos centros satisfacen $\alpha i + \beta j = s$.

- Implementar la función `mascara_rayo(n, direccion, s)`, que devuelva una matriz $M_r \in \{0, 1\}^{n \times n}$ con un 1 en los píxeles seleccionados por el rayo r y un 0 en los restantes.
- Visualizar las máscaras para las direcciones $(1, 0)$, $(0, 1)$, $(1, 1)$, $(1, -1)$ y $(2, 1)$, utilizando respectivamente los desplazamientos $s = 3, 5, 7, 0, 8$.
- Para cada máscara, calcular la medición $b_r = \sum_{i,j} (M_r)_{ij} (X_{\text{fantoma}})_{ij}$ mediante un producto componente a componente entre la máscara y el fantoma.
- Explicar por qué dos rayos con orientaciones diferentes pueden producir el mismo valor de medición aunque seleccionen distintos píxeles.

3. Sin IA Construcción de la matriz de proyección binaria

Continuaremos utilizando la matriz X_{fantoma} y su versión vectorizada $\mathbf{x}_{\text{fantoma}}$ construidas en el Ejercicio 1. El objetivo de este ejercicio es reunir las máscaras de distintos rayos en una única matriz de proyección A . Para cada rayo r , vectorizaremos su máscara M_r por filas y utilizaremos el vector resultante como la fila $\mathbf{a}_r^T$ de A . De este modo, si se generan m rayos para una imagen de $n \times n$ píxeles, entonces $A \in \mathbb{R}^{m \times n^2}$.

- Implementar la función `matriz_proyeccion(n, direcciones)`. Para cada dirección (α, β) , se deberán calcular los distintos valores de $s = \alpha i + \beta j$, ordenarlos de menor a mayor, construir la máscara correspondiente a cada uno y agregar su versión vectorizada como una fila de A .
- Hacer que la función devuelva también una lista con el par $((\alpha, \beta), s)$ asociado a cada fila de A , respetando el orden de las direcciones recibidas.
- Aplicar la función con $n = 8$ y `direcciones = [(1, 0), (0, 1)]`. Verificar que se obtienen 16 rayos y que $A \in \mathbb{R}^{16 \times 64}$.
- Explicar qué representa una fila de A y qué representa una columna. Visualizar la matriz mediante `plt.imshow` y explicar por qué contiene una gran cantidad de ceros.
- Calcular las mediciones $\mathbf{b} = A \mathbf{x}_{\text{fantoma}}$. Verificar que sus primeras ocho componentes coinciden con $X_{\text{fantoma}}.\text{sum}(\text{axis}=1)$ y las ocho restantes con $X_{\text{fantoma}}.\text{sum}(\text{axis}=0)$. Graficar ambos bloques como señales unidimensionales.

4. Asistencia para destrabar/corregir ¿Es posible reconstruir la imagen de manera única?

Continuaremos trabajando con la matriz X_{fantoma} y el vector $\mathbf{x}_{\text{fantoma}}$ del Ejercicio 1, junto con la función `matriz_proyeccion` implementada anteriormente. El objetivo es investigar si las mediciones $\mathbf{b} = A \mathbf{x}$ contienen información suficiente para recuperar una imagen de 8×8 de manera única. Para ello, analizaremos el rango y el espacio nulo de distintas matrices de proyección.

- Considerar una matriz de proyección $A \in \mathbb{R}^{m \times 64}$. Utilizando el teorema de rango y nulidad, determinar qué condición debe cumplir $\text{rango}(A)$ para que la imagen pueda reconstruirse de manera única. Explicar qué ocurre si existe un vector no nulo $\mathbf{v}$ tal que $A \mathbf{v} = \mathbf{0}$ y relacionar $\text{rango}(A)$ con $\dim(\text{Nul}(A))$.
- Construir las matrices A_2 , A_4 y A_7 utilizando $\mathcal{D}_2 = \{(1, 0), (0, 1)\}$; $\mathcal{D}_4 = \mathcal{D}_2 \cup \{(1, 1), (1, -1)\}$; y $\mathcal{D}_7 = \mathcal{D}_4 \cup \{(2, 1), (1, 2), (3, 1)\}$. Para cada matriz, informar sus dimensiones, su rango, la dimensión de su espacio nulo y si permite determinar una imagen de manera única. Comparar la cantidad de filas con el rango e identificar la presencia de mediciones redundantes.
- Para A_4 , utilizar una descomposición SVD para encontrar un vector no nulo $\mathbf{v} \in \mathbb{R}^{64}$ que pertenezca aproximadamente a su espacio nulo y verificar que $\|A_4 \mathbf{v}\| \approx 0$. Calcular $\mathbf{b}_4 = A_4 \mathbf{x}_{\text{fantoma}}$ y construir $\mathbf{x}_{\text{alt}} = \mathbf{x}_{\text{fantoma}} + \gamma \mathbf{v}$, con $\gamma \neq 0$. Visualizar y verificar que producen aproximadamente las mismas mediciones e interpretar qué información de la imagen resulta invisible para A_4 .

5. **Asistencia para destrabar/corregir** **Reconstrucción en condiciones ideales**

Continuaremos utilizando el vector $\mathbf{x}_{\text{fantoma}}$ del Ejercicio 1 y las matrices A_2 , A_4 y A_7 construidas anteriormente. Trabajaremos con mediciones ideales, sin ruido, para observar cómo el rango de la matriz de proyección afecta la reconstrucción. En particular, A_7 tiene rango columna completo, mientras que A_2 y A_4 no determinan una solución única.

- Para cada $k \in \{2, 4, 7\}$, generar las mediciones $\mathbf{b}_k = A_k \mathbf{x}_{\text{fantoma}}$ y resolver el sistema mediante `np.linalg.lstsq` para obtener una reconstrucción $\hat{\mathbf{x}}_k$. En los casos sin solución única, esta función devolverá una solución de norma mínima.
- Para cada reconstrucción, calcular el residuo $\mathbf{r}_k = \mathbf{b}_k - A_k \hat{\mathbf{x}}_k$ y su norma. Calcular también el error relativo dividiendo $\|\hat{\mathbf{x}}_k - \mathbf{x}_{\text{fantoma}}\|$ por $\|\mathbf{x}_{\text{fantoma}}\|$. Resumir en una tabla el rango de A_k , la norma del residuo y el error relativo.
- Visualizar, para cada caso, la imagen original, la reconstrucción y la diferencia entre ambas, utilizando la misma escala de color. Explicar por qué un residuo cercano a cero no garantiza que la imagen original haya sido recuperada correctamente y relacionar el resultado con el espacio nulo de A_k .

6. **Asistencia para destrabar/corregir** **Mediciones con ruido y mínimos cuadrados**

Continuaremos utilizando el vector $\mathbf{x}_{\text{fantoma}}$ del Ejercicio 1 y la matriz A_7 . Las mediciones ideales son $\mathbf{b}_7 = A_7 \mathbf{x}_{\text{fantoma}}$. Para simular una adquisición real, agregaremos ruido y obtendremos mediciones perturbadas $\mathbf{b}_\sigma = \mathbf{b}_7 + \boldsymbol{\eta}_\sigma$. Debido al ruido, en general no existirá una imagen que reproduzca exactamente todas las mediciones. Utilizaremos mínimos cuadrados para encontrar la imagen cuyas mediciones simuladas sean lo más cercanas posible a $\mathbf{b}_\sigma$.

- Fijar una semilla aleatoria y generar un único vector $\mathbf{z}$, del mismo tamaño que $\mathbf{b}_7$, con componentes gaussianas estándar. Calcular `escala = np.sqrt(np.mean(b7**2))`; este valor representa el tamaño típico de las mediciones. Para cada $\sigma \in \{0, 0,01, 0,03, 0,06, 0,10\}$, definir $\boldsymbol{\eta}_\sigma = \sigma \text{escala} \mathbf{z}$ y construir $\mathbf{b}_\sigma$. De este modo, $\sigma = 0,03$ representa un ruido cuya desviación estándar es aproximadamente el 3 % del tamaño típico de las mediciones.
- Para cada nivel de ruido, utilizar `np.linalg.lstsq` para obtener la reconstrucción $\hat{\mathbf{x}}_\sigma$ que minimiza $\|A_7 \mathbf{x} - \mathbf{b}_\sigma\|^2$. Registrar en una tabla la norma del ruido, la norma del residuo, el error relativo respecto de $\mathbf{x}_{\text{fantoma}}$ y los valores mínimo y máximo de la reconstrucción. Visualizar las imágenes reconstruidas utilizando una misma escala de color.
- Analizar los resultados: ¿cómo cambia el error de reconstrucción al aumentar σ ? ¿Por qué el residuo deja de ser nulo cuando se agrega ruido? ¿Por qué pueden aparecer valores negativos, aunque los coeficientes de atenuación del fantoma sean no negativos?

7. **Sin IA** **La reconstrucción como proyección ortogonal**

Continuaremos utilizando A_7 y las mediciones con $\sigma = 0,06$ del ejercicio anterior. La reconstrucción por mínimos cuadrados $\hat{\mathbf{x}}_\sigma$ no reproduce exactamente las mediciones ruidosas, sino que genera el vector $A_7 \hat{\mathbf{x}}_\sigma$ más cercano a $\mathbf{b}_\sigma$ dentro de $\text{Col}(A_7)$.

- Calcular el residuo $\mathbf{r}_\sigma = \mathbf{b}_\sigma - A_7 \hat{\mathbf{x}}_\sigma$ y verificar numéricamente que $\|A_7^T \mathbf{r}_\sigma\| \approx 0$.
- Explicar por qué el resultado anterior indica que el residuo es ortogonal a todas las columnas de A_7 y que $A_7 \hat{\mathbf{x}}_\sigma$ es la proyección ortogonal de $\mathbf{b}_\sigma$ sobre $\text{Col}(A_7)$.
- Explicar la diferencia entre las proyecciones tomográficas medidas por el escáner y la proyección ortogonal que aparece en mínimos cuadrados.

8. **Asistencia para destrabar/corregir** Mínimos cuadrados mediante métodos iterativos

Resolveremos nuevamente el problema de mínimos cuadrados para A_7 y las mediciones ruidosas $\mathbf{b}_\sigma$, pero esta vez utilizando métodos iterativos. Definimos la función objetivo como:

$$E(\mathbf{x}) = \frac{1}{2} \|A_7 \mathbf{x} - \mathbf{b}_\sigma\|^2.$$

Para este costo, utilizaremos el gradiente $\nabla E(\mathbf{x}) = A_7^T (A_7 \mathbf{x} - \mathbf{b}_\sigma)$ y la Hessiana constante $H = A_7^T A_7$.

- Interpretar las expresiones provistas e implementar funciones que calculen $E(\mathbf{x})$ y $\nabla E(\mathbf{x})$. Construir también H y verificar numéricamente que es simétrica.
- Implementar gradiente descendiente mediante $\mathbf{x}_{t+1} = \mathbf{x}_t - \alpha \nabla E(\mathbf{x}_t)$, comenzando con $\mathbf{x}_0 = \mathbf{0}$. Registrar el costo y la norma del gradiente durante las iteraciones.
- Calcular el mayor autovalor $\mu_{\max}$ de H y probar tasas de aprendizaje dentro y fuera del intervalo $0 < \alpha < 2/\mu_{\max}$. Comparar las curvas del costo y describir cuándo el método converge o se vuelve inestable.
- Implementar el método de Newton resolviendo $H \mathbf{p}_t = \nabla E(\mathbf{x}_t)$ mediante `np.linalg.solve` y actualizando $\mathbf{x}_{t+1} = \mathbf{x}_t - \mathbf{p}_t$. Verificar que alcanza la solución en una sola iteración y explicar por qué esto ocurre para una función cuadrática con Hessiana constante.
- Comparar las reconstrucciones obtenidas mediante gradiente descendiente, Newton y `lstsq`.

9. **IA necesaria** Reconstrucción tomográfica con regularización cuadrática

Continuaremos trabajando con la matriz A_7 y el fantoma $\mathbf{x}_{\text{fantoma}}$. El objetivo será estudiar cómo cambia la reconstrucción al modificar tanto el nivel de ruido como la intensidad de la regularización. Para medir las variaciones entre píxeles vecinos construiremos una matriz D . Recordemos que, al vectorizar la imagen por filas, el píxel (i, j) ocupa la posición $k = in + j$ del vector $\mathbf{x}$.

La matriz D estará formada por dos bloques:

$$D = \begin{pmatrix} D_h \\ D_v \end{pmatrix}.$$

Cada fila de D_h calculará una diferencia horizontal $X_{i,j+1} - X_{ij}$. Para ello, contendrá un -1 en la columna k y un 1 en la columna $k + 1$. Cada fila de D_v calculará una diferencia vertical $X_{i+1,j} - X_{ij}$, por lo que contendrá un -1 en la columna k y un 1 en la columna $k + n$. Existen $n(n - 1)$ pares horizontales y $n(n - 1)$ pares verticales. Por lo tanto, $D \in \mathbb{R}^{2n(n-1) \times n^2}$. Para $n = 8$, sus dimensiones serán 112×64 . El vector $D\mathbf{x}$ contendrá primero todas las diferencias horizontales y luego todas las verticales.

Para cada nivel de ruido σ y cada valor $\lambda \geq 0$, definimos

$$J_{\sigma,\lambda}(\mathbf{x}) = \frac{1}{2} \left(\|A_7 \mathbf{x} - \mathbf{b}_\sigma\|^2 + \lambda \|D\mathbf{x}\|^2 \right),$$

cuyo gradiente está dado por

$$\nabla J_{\sigma,\lambda}(\mathbf{x}) = A_7^T (A_7 \mathbf{x} - \mathbf{b}_\sigma) + \lambda D^T D \mathbf{x}.$$

- Implementar `matriz_diferencias(n)` siguiendo la construcción anterior. Verificar que cada fila contiene exactamente un -1 y un 1 , y comprobar que para $n = 8$ se obtiene $D \in \mathbb{R}^{112 \times 64}$.
- Crear en Python el vector `x_constante = np.ones(n**2)`, que representa una imagen en la que todos los píxeles tienen valor 1 . Verificar que $D\mathbf{x}_{\text{constante}} = \mathbf{0}$ y explicar por qué todas las diferencias resultan nulas. Comparar este resultado con $\|D\mathbf{x}_{\text{fantoma}}\|$.
- Interpretar las expresiones provistas. Explicar qué mide cada término de $J_{\sigma,\lambda}$, qué representa $\|D\mathbf{x}\|$ y cuál es el papel de λ .

- d) Reutilizar las mediciones limpias $\mathbf{b}_7 = A_7 \mathbf{x}_{\text{fantoma}}$ y el vector aleatorio $\mathbf{z}$ del ejercicio sobre ruido. Generar mediciones para $\sigma \in \{0, 0,10, 0,20\}$ mediante:
- ```
escala = np.sqrt(np.mean(b7**2))
b_sigma = b7 + sigma * escala * z
```

Utilizar el mismo vector  $\mathbf{z}$  en los tres casos, de modo que sólo cambie la intensidad del ruido.

- e) Adaptar gradiente descendiente para minimizar  $J_{\sigma,\lambda}$  para cada combinación de  $\sigma \in \{0, 0,10, 0,20\}$  y  $\lambda \in \{0, 0,1, 0,3, 1\}$ . Comenzar siempre con  $\mathbf{x}_0 = \mathbf{0}$ .
- f) Evaluar distintas tasas de aprendizaje y seleccionar una que produzca un descenso estable del costo. Implementar un criterio de parada basado en la norma del gradiente o en la variación del costo, junto con una cantidad máxima de iteraciones. El criterio de parada no debe utilizar el error respecto del fantoma.
- g) Registrar durante las iteraciones el error relativo  $e_t = \|\mathbf{x}_t - \mathbf{x}_{\text{fantoma}}\| / \|\mathbf{x}_{\text{fantoma}}\|$ . Para cada nivel de ruido, graficar  $e_t$  en función de las iteraciones para los distintos valores de  $\lambda$ .
- h) Organizar las reconstrucciones finales en una grilla: cada fila debe corresponder a un valor de  $\sigma$  y cada columna, a un valor de  $\lambda$ . Utilizar la misma escala de color en todas las imágenes, sin ajustar automáticamente los límites de cada panel, e indicar el error relativo sobre cada reconstrucción.
- i) Resumir los errores relativos y las normas de los residuos en una tabla o mapa de calor cuyos ejes sean  $\sigma$  y  $\lambda$ . Para cada nivel de ruido, identificar qué valor de  $\lambda$  produjo el menor error.
- j) Analizar los resultados. ¿En qué casos la regularización mejoró la reconstrucción obtenida con  $\lambda = 0$ ? ¿Cómo cambió el valor más conveniente de  $\lambda$  al aumentar el ruido? ¿Qué efecto produjo una regularización excesiva?

#### 10. IA necesaria Aplicación final: reconstruir una imagen desconocida

En los primeros ejercicios utilizamos un modelo binario, en el que cada entrada de  $A$  indicaba solamente si el centro de un píxel pertenecía o no a un rayo. En este último ejercicio abandonaremos ese modelo simplificado y utilizaremos una matriz de proyección basada en la geometría de los rayos.

La entrada  $a_{r,j}$  representa la longitud del tramo del rayo  $r$  contenido dentro del píxel  $j$ . Por lo tanto, todo píxel atravesado por el rayo contribuye a la medición de manera proporcional a la longitud recorrida en su interior:

$$b_r = \sum_j a_{r,j} x_j.$$

Los datos y la función de carga se encuentran en [esta carpeta de drive](#).

El archivo `datos_tomografia_final_128.npz` contiene mediciones simuladas de una imagen desconocida de  $128 \times 128$  píxeles. Incluye la resolución  $n$ , la matriz de proyección dispersa  $A$ , el vector de mediciones ruidosas  $\mathbf{b}$ , los ángulos  $\theta_0, \dots, \theta_{K-1}$ , las posiciones de detector  $s_0, \dots, s_{q-1}$  y una estimación del ruido. La imagen original permanecerá oculta hasta después de la entrega.

Las filas de  $A$  y las componentes de  $\mathbf{b}$  están ordenadas primero por ángulo y luego por posición de detector. Por lo tanto, la fila  $r = kq + j$  corresponde al rayo  $(\theta_k, s_j)$ . Como  $A$  es una matriz dispersa, deberá cargarse mediante la función provista en `cargar_datos_tomografia.py` y no deberá convertirse en una matriz densa.

- a) Cargar los datos y determinar  $K$  y  $q$  a partir de las cantidades de ángulos y posiciones de detector. Verificar que  $A \in \mathbb{R}^{Kq \times n^2}$  y que  $\mathbf{b} \in \mathbb{R}^{Kq}$ .
- b) Organizar las mediciones en una matriz  $S \in \mathbb{R}^{K \times q}$  utilizando  $S_{kj} = b_{kq+j}$ . Visualizar  $S$  como un sinograma, indicando en sus ejes los valores de  $s$  y  $\theta$ .
- c) Adaptar `matriz_diferencias(n)` para construir  $D$  como una matriz dispersa. Verificar que  $D \in \mathbb{R}^{2n(n-1) \times n^2}$  y que cada fila contiene exactamente dos valores no nulos.
- d) Obtener una reconstrucción sin regularización, correspondiente a  $\lambda = 0$ , reutilizando el método de gradiente descendiente desarrollado anteriormente. Convertir el vector resultante en una

- imagen de  $n \times n$  y visualizarla.
- e) Obtener reconstrucciones regularizadas minimizando

$$J_{\lambda}(\mathbf{x}) = \frac{1}{2} \left( \|\mathbf{Ax} - \mathbf{b}\|^2 + \lambda \|\mathbf{Dx}\|^2 \right).$$

- Comenzar explorando  $\lambda \in \{0, 1, 10, 30, 100\}$  y, si lo consideran necesario, probar valores adicionales.
- f) Para cada reconstrucción, registrar  $\lambda$ , la tasa de aprendizaje, la cantidad de iteraciones, la norma del residuo  $\|\mathbf{A}\hat{\mathbf{x}}_{\lambda} - \mathbf{b}\|$ , la medida de variación  $\|\mathbf{D}\hat{\mathbf{x}}_{\lambda}\|$  y sus valores mínimo y máximo. Comparar la norma del residuo con la estimación del ruido incluida en los datos.
- g) Elegir la reconstrucción que consideren más adecuada sin conocer la imagen original. Presentar una figura con el sinograma construido, la reconstrucción sin regularización y al menos tres reconstrucciones regularizadas, utilizando una escala de color común. Justificar la elección considerando el ruido, el residuo, y la preservación de estructuras en la imagen.

11. **Asistencia para destrabar/corregir** **Reflexión final**

Responder brevemente, apoyándose en las ecuaciones, los resultados numéricos y las visualizaciones obtenidas durante el trabajo:

- a) ¿Por qué la reconstrucción tomográfica se considera un *problema inverso*? Identificar qué información se conoce, qué variable se busca recuperar y qué papel cumple el modelo  $\mathbf{b} = \mathbf{Ax}$ .
- b) ¿Cómo puede determinarse, a partir de  $\mathbf{A}$ , si las mediciones permiten recuperar una única imagen? Relacionar la respuesta con el rango y el espacio nulo de  $\mathbf{A}$ , y considerar qué ocurre cuando existe  $\mathbf{v} \neq \mathbf{0}$  tal que  $\mathbf{Av} = \mathbf{0}$ .
- c) ¿Cómo afecta el ruido al sistema de ecuaciones? Explicar qué problema resuelve el método de mínimos cuadrados, interpretar el residuo obtenido y discutir si su norma es suficiente para evaluar la calidad de una reconstrucción.
- d) ¿Qué supuesto sobre la imagen introduce el término  $\|\mathbf{Dx}\|^2$ ? Analizar cómo cambian las reconstrucciones al modificar  $\lambda$  y justificar las diferencias observadas.
- e) Comparar `np.linalg.lstsq`, gradiente descendiente y Newton considerando las iteraciones necesarias, los parámetros que requiere cada método y las soluciones obtenidas. Explicar el comportamiento observado para Newton.
- f) Elaborar una síntesis que conecte el modelo  $\mathbf{b} = \mathbf{Ax}$  con el rango, el espacio nulo, las proyecciones ortogonales, mínimos cuadrados y la regularización. Indicar qué aspecto del problema de reconstrucción permite analizar cada concepto.